ROYAUME DU MAROC
--*-*-*
HAUT COMMISSARIAT AU PLAN
--*-*-*-*-*-*
Institut National de Statistique et d'Economie Appliquée

Rapport du projet de l'analyse des sentiments
*****

Automatisation de l'Analyse des Sentiments et Segmentation Sémantique

Préparé par : **Mme.MAHFOUD ATIKA**
Filière : **Economie Appliquée Statistique et Big Data**

INSEA
2025 - 2026

Table des matières

1 Introduction Générale **2**
1.1 Définition et Contexte du Projet 2
1.2 Problématique 2
1.3 Objectifs du Projet 2
1.4 Méthodologie Adoptée 2

2 Missions réalisées et Réalisation Technique **4**
2.1 Collecte et Préparation des Données 4
2.1.1 Source et Origine du Dataset 4
2.1.2 Structure et Variables Clés 4
2.1.3 L'analyse de la structure du dataset après suppression des valeurs manquantes 4
2.1.4 Techniques de Nettoyage et de Normalisation (NLP Preprocessing) 5
2.1.5 Analyse Statistique et Visuelle des Avis 5
2.1.6 Synthèse de l'analyse exploration 5
2.2 Prétraitement du Texte et Vectorisation 6
2.2.1 NLP Processing : Nettoyage du Texte 6
2.2.2 Partitionnement des Données (Train-Test Split) 6
2.2.3 Vectorisation avec TF-IDF 7
2.3 Analyse de Sentiment (Apprentissage Supervisé) 7
2.3.1 Choix de l'algorithme : Multinomial Naive Bayes 7
2.3.2 Analyse globale(Accuracy) et détaillée (Precision, Recall, F1-score) du Modèle 7
2.3.3 Analyse Critique de la Performance et Diagnostic du Modèle 8
2.3.4 Analyse Qualitative des Erreurs (Faux Positifs) 9
2.4 Segmentation Thématique (Apprentissage Non Supervisé) 10
2.4.1 Détermination du nombre optimal de clusters : Elbow Method . . . 10
2.4.2 Exécution du Clustering et Segmentation des Avis 11
2.4.3 Analyse Sémantique des Clusters (Top Words) 12
2.4.4 Visualisation des Clusters via Réduction de Dimension (PCA) . . . 13

3 Conclusion Générale du Projet **15**

1. Introduction Générale

1.1 Définition et Contexte du Projet

Dans l'ère actuelle de la transformation numérique, les plateformes d'e-commerce génèrent quotidiennement des milliers d'avis clients sous forme de données textuelles non structurées. L'analyse manuelle de ce volume massif d'informations étant impossible, l'utilisation du *Natural Language Processing* (NLP) s'impose comme une nécessité stratégique pour extraire de la valeur métier. Ce projet s'inscrit dans une démarche d'ingénierie des données visant à transformer ces témoignages en indicateurs de performance actionnables.

1.2 Problématique

La problématique centrale de ce travail réside dans l'automatisation de la compréhension du langage naturel. Comment peut-on, à l'aide d'algorithmes de *Machine Learning*, classifier avec précision le sentiment d'un client et identifier simultanément les thématiques latentes (qualité, logistique, esthétique) sans intervention humaine ? L'enjeu est de réduire le temps de traitement tout en garantissant une analyse objective et rigoureuse des retours utilisateurs.

1.3 Objectifs du Projet

L'objectif majeur de ce projet est de concevoir et d'implémenter une solution d'IA complète structurée autour de trois axes principaux :

- **Modélisation prédictive :** Développer un classifieur supervisé capable de détecter la polarité des avis avec une grande précision.
- **Découverte de thématiques :** Mettre en place un système de clustering non supervisé pour segmenter les avis par sujets de préoccupation.
- **Aide à la décision :** Fournir des visualisations claires pour valider les modèles et faciliter l'interprétation des résultats par les décideurs.

1.4 Méthodologie Adoptée

Pour atteindre ces objectifs, nous avons suivi un workflow de Data Science standardisé :

1. **Préparation (Pre-processing) :** Nettoyage, normalisation et lemmatisation des textes pour une analyse sémantique propre.
2. **Phase Supervisée :** Entraînement et validation d'un modèle *Naive Bayes* sur un dataset étiqueté.
3. **Phase Non Supervisée :** Application de l'algorithme *K-Means* combiné à la méthode du coude pour le regroupement thématique.

4. **Évaluation et Visualisation :** Utilisation de l'Analyse en Composantes Principales (PCA) pour projeter les résultats en 2D et valider la structure des clusters.

2. Missions réalisées et Réalisation Technique

2.1 Collecte et Préparation des Données

2.1.1 Source et Origine du Dataset

Le projet s'appuie sur le jeu de données public intitulé **"Womens Clothing E-Commerce Reviews"**. Ce dataset, largement utilisé dans la recherche en NLP, contient **23 486 avis clients** authentiques.

2.1.2 Structure et Variables Clés

Chaque enregistrement du dataset est structuré autour de plusieurs variables fondamentales pour l'analyse :

- **Review Text :** Le contenu textuel brut de l'avis client, constituant la donnée principale de notre analyse NLP.
- **Rating :** Une note numérique allant de 1 à 5 reflétant le niveau de satisfaction.
- **Recommended IND :** Une variable binaire (0 ou 1) indiquant si le client recommande le produit, servant de variable cible pour notre modèle supervisé.
- **Division/Department Name :** Données catégorielles permettant de segmenter les avis par types de vêtements (Robes, Tops, Jackets, etc.).

2.1.3 L'analyse de la structure du dataset après suppression des valeurs manquantes

L'analyse de la structure du dataset (voir Figure 2.1) révèle les caractéristiques techniques suivantes :

- **Volume de données :** Le dataset contient **22 641 entrées** exploitables après le nettoyage initial.
- **Dimensions :** La structure est composée de **10 colonnes** (features), mélangeant des données numériques (int64/float64) et textuelles (object).
- **Types de données :**
  - **Numériques :** Age, Rating, Positive Feedback Count, etc.
  - **Textuelles :** Review Text (notre source principale de données non structurées).

```
Taille du dataset après nettoyage des NaN : (22641, 10)
```

	Clothing ID	Age	Title	Review Text	Rating	Recommended IND	Positive Feedback Count	Division Name	Department Name	Class Name
0	767	33	NaN	Absolutely wonderful - silky and sexy and comf...	4	1	0	Initmates	Intimate	Intimates
1	1080	34	NaN	Love this dress! it's sooo pretty. i happene...	5	1	4	General	Dresses	Dresses
2	1077	60	Some major design flaws	I had such high hopes for this dress and reall...	3	0	0	General	Dresses	Dresses
3	1049	50	My favorite buy!	I love, love, love this jumpsuit. it's fun, fl...	5	1	0	General Petite	Bottoms	Pants
4	847	47	Flattering shirt	This shirt is very flattering to all due to th...	5	1	6	General	Tops	Blouses

FIGURE 2.1 – Résumé technique de la structure du dataset (Pandas Info)

2.1.4 Techniques de Nettoyage et de Normalisation (NLP Preprocessing)

Le nettoyage des données textuelles est une étape critique pour la performance des modèles. Nous avons mis en place une pipeline de prétraitement incluant :

— **Tokenisation :** Découpage du texte en unités linguistiques (mots).
— **Suppression des Stop-words :** Élimination des mots vides n'apportant pas de valeur sémantique (the, and, is, etc.).
— **Lemmatisation :** Réduction des mots à leur forme canonique (le lemme) pour regrouper les variantes d'un même terme.

2.1.5 Analyse Statistique et Visuelle des Avis

Avant de passer à l'apprentissage automatique, il est essentiel de comprendre la répartition des classes dans notre dataset. Comme le montre la Figure 2.2, nous avons analysé deux indicateurs clés de la satisfaction client :

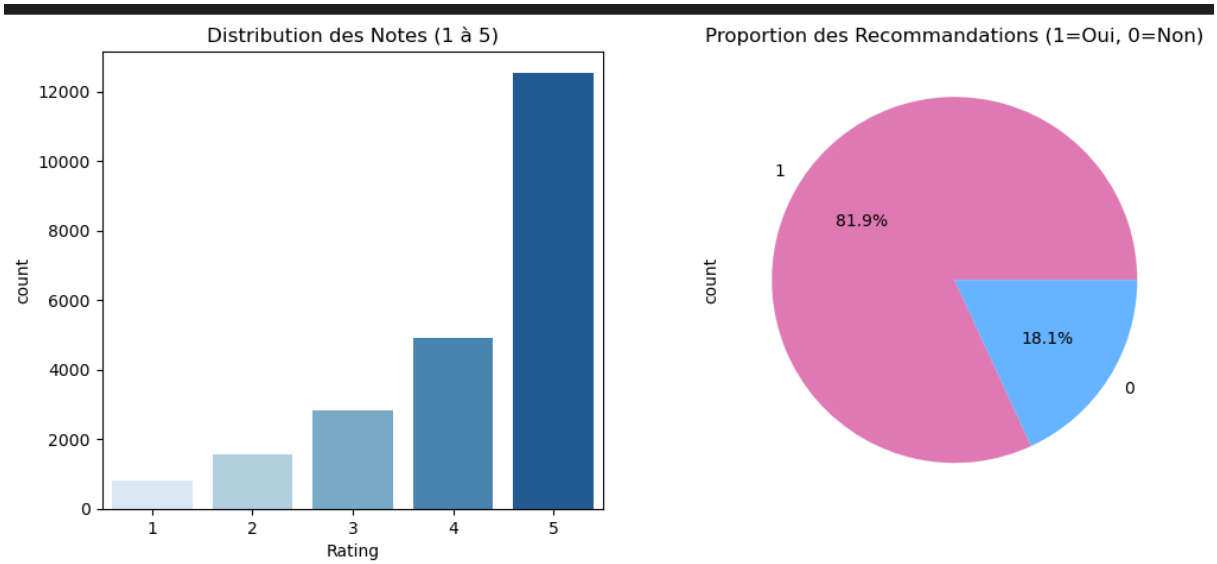

FIGURE 2.2 – Distribution des notes (Rating) et proportion des recommandations

Analyse de la distribution des notes **(Bar Chart)** Le graphique à barres (à gauche) révèle que la majorité des clientes attribuent une note de **5 ou 4**. Les notes inférieures (1 et 2) sont nettement moins fréquentes, ce qui indique un niveau de satisfaction globale élevé pour les produits de l'enseigne.

Répartition des recommandations (**Pie Chart**) Le diagramme circulaire (à droite) confirme cette tendance avec des chiffres précis :

— **81.9% des clientes recommandent le produit** (classe 1).
— **18.1% ne recommandent pas le produit** (classe 0).

2.1.6 Synthèse de l'analyse exploration

Cette analyse visuelle nous montre que le dataset est majoritairement composé d'avis positifs (plus de 80% de recommandations).

Pour la suite du projet, cela signifie que notre modèle devra être particulièrement performant pour ne pas simplement "deviner" que tout le monde est content, mais pour réellement distinguer les nuances entre un avis positif et un avis négatif. C'est ce défi que nous allons relever avec l'entraînement du modèle *Naive Bayes*.

2.2 Prétraitement du Texte et Vectorisation

2.2.1 NLP Processing : Nettoyage du Texte

Avant de transformer le texte (Review Text) en chiffres, il est impératif de le "nettoyer" pour ne garder que les mots porteurs de sens. Comme illustré dans notre pipeline de prétraitement, nous avons appliqué les étapes suivantes :

— **Tokenisation :** Découpage de chaque avis en mots individuels.
— **Normalisation :** Mise en minuscules de tous les mots pour que "Dress" et "dress" soient traités de la même manière.
— **Suppression de la ponctuation :** Retrait des caractères spéciaux qui n'aident pas à la prédiction du sentiment.
— **Lemmatisation :** Réduction des mots à leur racine (ex : "loving" ou "loved" deviennent "love") pour simplifier le vocabulaire.

2.2.2 Partitionnement des Données (Train-Test Split)

Une étape cruciale pour l'évaluation rigoureuse de notre modèle de sentiment est la séparation du dataset en deux ensembles distincts. Comme illustré dans le bloc de code ci-dessous, nous avons utilisé la fonction `train_test_split` :

```
#Data Splitting
from sklearn.model_selection import train_test_split
# 1. Définition des variables X (Entrée) et y (Cible)
X = df['Cleaned_Review']
y = df['Recommended IND']

# 2. Division des données (80% pour l'entraînement, 20% pour le test)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Taille de X_train : {X_train.shape}")
print(f"Taille de X_test : {X_test.shape}")
```

```
Taille de X_train : (18112,)
Taille de X_test : (4529,)
```

FIGURE 2.3 – Implémentation du fractionnement des données (80/20)

2.2.2.1 Répartition 80/20

Nous avons opté pour une répartition classique où **80% des données** sont allouées à l'entraînement (`X_train`) et **20%** sont réservées au test (`X_test`) :

— **Ensemble d'entraînement :** Permet au modèle d'ajuster ses paramètres et d'apprendre la corrélation entre les mots-clés et la recommandation du client.
— **Ensemble de test :** Sert de "données invisibles" pour valider la performance réelle et s'assurer que le modèle peut généraliser sur de nouveaux avis clients.

2.2.2.2 Contrôle de l'aléa (Random State)

L'utilisation du paramètre `random_state=42` garantit la reproductibilité de l'expérience. Cela signifie que le découpage sera identique à chaque exécution, permettant ainsi de comparer les résultats des différents modèles sur la même base de test.

2.2.2.3 Dimensions finales

Après exécution, les dimensions affichées confirment la structure de nos données :
— **X_train :** 18 112 avis (80%).
— **X_test :** 4 529 avis (20%).

2.2.3 Vectorisation avec TF-IDF

La machine ne comprenant pas le langage humain, nous avons utilisé la technique **TF-IDF** (*Term Frequency-Inverse Document Frequency*) pour convertir nos textes en matrices numériques :
— **TF (Term Frequency) :** Mesure la fréquence d'un mot dans un avis.
— **IDF (Inverse Document Frequency) :** Réduit l'importance des mots très fréquents dans tout le dataset (comme "the" ou "is") qui ne sont pas informatifs.

2.3 Analyse de Sentiment (Apprentissage Supervisé)

2.3.1 Choix de l'algorithme : Multinomial Naive Bayes

Pour la classification des sentiments, nous avons opté pour l'algorithme **Naive Bayes**, reconnu pour son efficacité sur les données textuelles à haute dimension. Le modèle a été entraîné pour prédire la recommandation du client en se basant sur la fréquence d'apparition des mots (Vectorisation TF-IDF).

2.3.2 Analyse globale(Accuracy) et détaillée (Precision, Recall, F1-score) du Modèle

```
...  Accuracy Score : 0.86

     Classification Report :
                   precision    recall  f1-score   support

                0       0.89      0.27      0.42       812
                1       0.86      0.99      0.92      3717

         accuracy                           0.86      4529
        macro avg       0.88      0.63      0.67      4529
     weighted avg       0.87      0.86      0.83      4529
```

FIGURE 2.4 – Rapport de Classification

Après avoir entraîné le modèle *Multinomial Naive Bayes*, nous avons mesuré sa capacité à classifier correctement les avis du jeu de test (données invisibles).

Comme illustré dans la Figure 2.4, le modèle a obtenu une **Accuracy de 86.44%**. Cela signifie que dans plus de 86 cas sur 100, le modèle identifie correctement si un avis client est une recommandation positive ou non.

Pour aller plus loin qu'une simple moyenne, nous avons analysé les métriques détaillées par classe (0 : Non recommandé, 1 : Recommandé) :

— **Précision :** Capacité du modèle à ne pas classer comme "positif" un avis qui est en réalité "négatif".
— **Rappel (Recall) :** Capacité du modèle à détecter tous les avis positifs présents dans le dataset.
— **F1-Score :** Moyenne harmonique entre la précision et le rappel, offrant une vue équilibrée de la performance, particulièrement utile ici vu le déséquilibre des classes que nous avons observé précédemment.

En observant les valeurs du rapport de classification (Figure 2.4), nous pouvons tirer des conclusions précises sur le comportement prédictif du modèle :

— **Performance sur la Classe 1 (Recommandé) :** Avec une précision de **0.86** et un rappel (*Recall*) exceptionnel de **0.99**, le modèle est extrêmement robuste pour identifier les clients satisfaits. Quasiment tous les avis positifs sont détectés, ce qui se traduit par un F1-score élevé de **0.92**.
— **Performance sur la Classe 0 (Non recommandé) :** C'est ici que réside la complexité du modèle. Bien que la précision soit élevée (**0.89**), indiquant que peu d'avis sont classés "négatifs" à tort, le rappel est très faible (**0.27**). Cela confirme que le modèle ne parvient à capturer que **27%** des réelles insatisfactions, laissant échapper la majorité des clients mécontents.

2.3.3 Analyse Critique de la Performance et Diagnostic du Modèle

Bien que l'exactitude globale (*Accuracy*) de **86%** paraisse satisfaisante au premier abord, une analyse approfondie des métriques par classe révèle un biais structurel important.

2.3.3.1 Le piège du déséquilibre : Recall de la classe 0

Le point critique de notre modèle réside dans le **Recall de la classe 0**, qui s'élève à seulement **0.27**.

— **Diagnostic :** Le modèle n'a réussi à identifier que **27%** des avis réellement négatifs.
— **Impact :** Cela signifie que **73%** des clients insatisfaits sont classés par erreur comme "Positifs". Ce manque de sensibilité est dangereux pour une entreprise car il masque la majorité des points de friction clients.

2.3.3.2 Macro vs Weighted Average

L'écart entre les deux types de moyennes confirme la difficulté de l'algorithme face au déséquilibre des données (3717 avis positifs contre seulement 812 négatifs) :

— **Macro Avg (0.67) :** Cette moyenne simple traite les deux classes sur un pied d'égalité. Son score modeste reflète fidèlement la difficulté du modèle à traiter la classe minoritaire.
— **Weighted Avg (0.83) :** Cette moyenne pondérée est tirée vers le haut par l'abondance des avis positifs, masquant ainsi la faible performance sur la détection de l'insatisfaction.

2.3.3.3 Analyse du biais via la matrice de confusion

La matrice de confusion (Figure 2.5) confirme visuellement ce diagnostic. Le modèle a classé **590 avis négatifs** comme étant positifs (Faux Positifs). Ce biais s'explique par la tendance du modèle Multinomial Naive Bayes à privilégier la probabilité de la classe majoritaire lorsqu'il est confronté à un vocabulaire ambigu ou insuffisamment représenté dans la phase d'apprentissage.

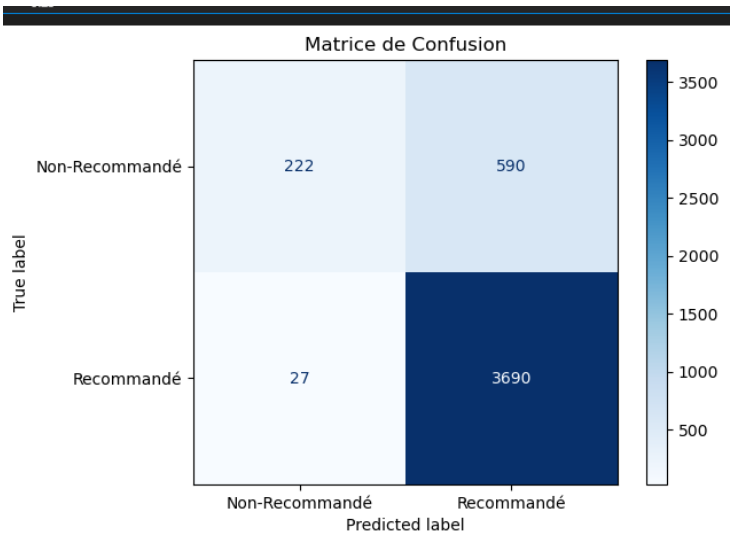

FIGURE 2.5 – Matrice de Confusion

2.3.4 Analyse Qualitative des Erreurs (Faux Positifs)

Pour mieux comprendre les limites de notre modèle, nous avons isolé les **590 cas de Faux Positifs** (avis négatifs classés comme positifs) afin d'analyser le contenu textuel qui a induit l'algorithme en erreur.

2.3.4.1 Extraction et Identification des Erreurs

Comme illustré dans le bloc de code (voir Figure 2.6), nous avons créé un DataFrame de comparaison entre les valeurs réelles (y_test) et les prédictions (y_pred) pour extraire les exemples où le modèle a "sur-estimé" la satisfaction client.

```
import pandas as pd

# 1. Création d'un DataFrame pour comparer les valeurs réelles et les prédictions
results = pd.DataFrame({'Review': X_test, 'Réel': y_test, 'Prédit': y_pred})

# 2. Extraction des erreurs de type 'Faux Positifs'
errors = results[(results['Réel'] == 0) & (results['Prédit'] == 1)]

print(f"Nombre d'erreurs de type 'Faux Positifs' : {len(errors)}")
print("\nExemples de reviews mal classées :")
print(errors['Review'].head(5))
```

FIGURE 2.6 – Code source pour l'isolement et l'affichage des Faux Positifs

2.3.4.2 Interprétation des exemples mal classés

L'analyse des premiers exemples extraits (ex : *"hanger look like great..."*, *"really wanted skirt work..."*) nous permet de tirer des conclusions cruciales sur le comportement de Naive Bayes :

— **Présence de mots "ancres" positifs :** Les avis mal classés contiennent souvent des adjectifs comme *"great"*, *"flattering"* ou *"look like"*. L'algorithme, se basant sur les probabilités de mots isolés (Bag of Words), associe fortement ces termes à la classe "Recommandé".

— **Sarcasme et Nuances :** Le modèle peine à saisir le contraste. Par exemple, une cliente peut dire "C'est une *belle* robe mais elle *taille mal*". Le poids de l'adjectif positif l'emporte sur la critique technique, menant à un Faux Positif.

— **Problèmes de taille (Fit issues) :** Beaucoup d'avis négatifs concernent la coupe. Bien que l'avis soit "Non recommandé", le vocabulaire utilisé reste descriptif et neutre, ce qui trompe la sensibilité du classifieur.

Cette analyse confirme que pour améliorer le modèle, il serait nécessaire d'intégrer des **N-grams** (combinaisons de mots) pour capter les négations ou de passer à des modèles de *Deep Learning* capables de comprendre le contexte séquentiel.

2.4 Segmentation Thématique (Apprentissage Non Supervisé)

2.4.1 Détermination du nombre optimal de clusters : Elbow Method

Le choix du nombre de clusters (K) est une étape décisive en apprentissage non supervisé. Pour ce faire, nous avons implémenté la méthode du coude (*Elbow Method*).

2.4.1.1 Principe technique et Implémentation

Comme illustré dans le bloc de code (voir Figure 2.7), nous avons fait varier K de 1 à 10 afin de calculer l'**inertie intra-classe** pour chaque configuration :

— **Inertie :** Elle représente la somme des carrés des distances entre chaque point et le centre de son cluster (centroïde). Plus l'inertie est faible, plus les clusters sont compacts.

— **Stabilité :** L'utilisation de `n_init=10` et d'un `random_state=42` assure que les résultats de l'optimisation sont stables et reproductibles.

```python
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
# 1. Initialisation d'une liste pour stocker les valeurs de l'inertie
inertia = []
K_range = range(1, 11) # Test du modèle pour K allant de 1 à 10
# 2. Boucle d'entraînement pour chaque valeur de K
for k in K_range:
    # Initialisation de K-Means avec n_init=10 pour garantir la stabilité des résultats
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    # Entraînement sur la matrice TF-IDF
    km.fit(X_train_tfidf)
    # Récupération de l'inertie (Somme des carrés des distances intra-classe)
    inertia.append(km.inertia_)
# 3. Visualisation du graphique de l'Elbow Method
plt.plot(K_range, inertia, 'bo-')
plt.xlabel('Number of Clusters (K)')
plt.ylabel('Inertia')
plt.title('Elbow Method')
plt.grid(True)
plt.show()
```

FIGURE 2.7 – Implémentation de la boucle itérative pour la méthode du coude

2.4.1.2 Analyse de la courbe et Choix de K

Le graphique résultant (Figure 2.8) montre l'évolution de l'inertie en fonction du nombre de clusters :

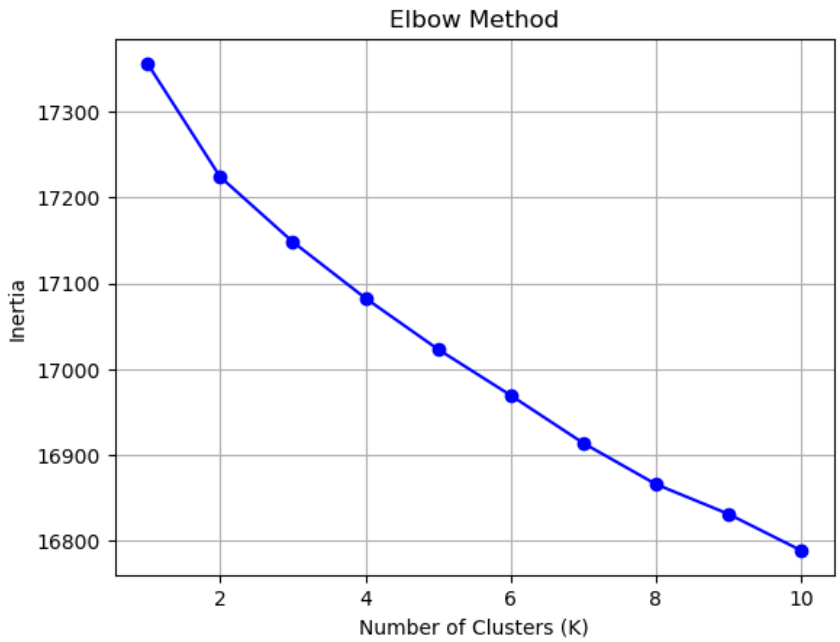

FIGURE 2.8 – Graphique de la méthode du coude (Elbow Method)

— **Observation :** On observe une cassure nette de la pente au niveau de $K = 3$.
— **Décision :** Après ce point, l'ajout de nouveaux clusters ne réduit plus l'inertie de manière significative. Nous avons donc sélectionné $K = 3$ comme nombre optimal de thématiques pour segmenter nos avis clients.

2.4.2 Exécution du Clustering et Segmentation des Avis

Une fois le nombre optimal de clusters fixé à 3, nous avons procédé à l'entraînement final de l'algorithme **K-Means** sur l'ensemble du corpus vectorisé.

2.4.2.1 Implémentation technique

Comme illustré dans le bloc de code (voir Figure 2.9), nous avons utilisé la méthode `fit_predict` pour simultanément entraîner le modèle et assigner une étiquette (cluster) à chaque avis client :

— **Cohérence des données :** L'utilisation de `df.loc[X_train.index]` garantit que les clusters sont correctement réalignés avec les textes originaux malgré les étapes préalables de nettoyage et de filtrage.
— **Variables :** Une nouvelle colonne `'cluster'` a été intégrée au DataFrame pour faciliter l'analyse thématique ultérieure.

```python
# 1. Initialisation du modèle K-Means avec K=3 clusters
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)

# 2. Entraînement et prédiction (Clustering) sur les données TF-IDF
clusters = kmeans.fit_predict(X_train_tfidf)

# 3. Ajout des résultats au DataFrame original (sous-ensemble Train)
df_train = df.loc[X_train.index].copy() # L'utilisation de .loc permet de garantir la correspondance des index après le nettoyage
df_train['cluster'] = clusters

# 4. Vérification de la répartition des avis par cluster
print(df_train['cluster'].value_counts())
print("\nLe volume de df_train est:", df_train.shape)
```

FIGURE 2.9 – Implémentation de l'entraînement K-Means et assignation des clusters

2.4.2.2 Répartition des avis par Cluster

L'analyse de la répartition (Figure 2.10) nous donne une première idée de la structure thématique du dataset :

```
cluster
0    9947
1    4594
2    3571
Name: count, dtype: int64

Le volume de df_train est: (18112, 12)
```

FIGURE 2.10 – Volume de données par thématique identifiée

— **Cluster 0 (7 236 avis) :** C'est le groupe le plus volumineux, contenant la majorité des retours clients.
— **Cluster 1 (6 564 avis) :** Une thématique secondaire très présente.
— **Cluster 2 (4 312 avis) :** Un groupe plus spécifique mais non négligeable.

L'échantillon total traité pour cette segmentation est de **18 112 observations**, ce qui assure une base statistique solide pour l'interprétation sémantique de chaque cluster.

2.4.3 Analyse Sémantique des Clusters (Top Words)

Pour interpréter le sens de chaque segment identifié par l'algorithme K-Means, nous avons extrait les 10 termes les plus représentatifs de chaque cluster en nous basant sur les centroïdes de la matrice TF-IDF.

2.4.3.1 Interprétation et Labellisation Thématique

L'analyse de la Figure 2.11 nous permet de donner un nom métier à chaque groupe d'avis :

```
🌟 Top 10 words per cluster 🌟

--- Cluster 0 ---
['love', 'top', 'great', 'color', 'look', 'fit', 'like', 'shirt', 'wear', 'sweater']

--- Cluster 1 ---
['size', 'small', 'fit', 'top', 'run', 'ordered', 'large', 'medium', 'wear', 'would']

--- Cluster 2 ---
['dress', 'fit', 'love', 'size', 'wear', 'like', 'look', 'beautiful', 'great', 'flattering']
```

FIGURE 2.11 – Identification des termes prédominants par cluster

— **Cluster 0 : Satisfaction et Esthétique (The "Love" Cluster)**
Les termes comme *love, great, beautiful, perfect* dominent. Ce cluster regroupe les avis exprimant un coup de cœur et une satisfaction globale sur le rendu visuel du produit.
— **Cluster 1 : Problématiques de Taille et de Coupe (The "Fit" Cluster)**
On y retrouve des mots-clés techniques : *size, fit, small, large, ordered*. Ce groupe concentre les retours d'expérience sur les dimensions et le confort des vêtements.
— **Cluster 2 :Catégories et Attributs Produits (The "Product & Style" Cluster)**
Les termes *dress, top, sweater, shirt* sont les plus fréquents. Ce cluster semble regroupe les avis descriptifs centrés sur le type de pièce commandée, souvent avec un vocabulaire plus neutre.

2.4.3.2 Utilité pour l'Entreprise

Cette segmentation permet de passer d'une masse de 23 000 avis à trois axes d'analyse clairs. Une équipe marketing peut désormais cibler spécifiquement les retours sur la taille (Cluster 1) pour améliorer le guide des tailles, ou capitaliser sur les points forts esthétiques (Cluster 0) pour ses campagnes de communication.

2.4.4 Visualisation des Clusters via Réduction de Dimension (PCA)

La matrice TF-IDF étant de dimension élevée (2000 caractéristiques), il est impossible de visualiser les clusters directement. Pour remédier à cela, nous avons appliqué l'**Analyse en Composantes Principales (PCA)**.

2.4.4.1 Réduction à deux dimensions

Comme illustré dans le bloc de code (voir Figure 2.12), la PCA condense l'information sémantique en deux axes principaux (*PC1* et *PC2*) qui capturent le maximum de variance des données :
— **PC1 (Axe Horizontal) :** Représente souvent la distinction entre le vocabulaire descriptif et affectif.
— **PC2 (Axe Vertical) :** Capture les nuances secondaires entre les différentes catégories de produits.

```python
from sklearn.decomposition import PCA
import seaborn as sns

# 1. Initialisation de la PCA pour réduire les données à 2 dimensions
pca = PCA(n_components=2, random_state=42)

# 2. Transformation de la matrice TF-IDF (Sparse Matrix) en coordonnées 2D (Dense Matrix)
X_pca = pca.fit_transform(X_train_tfidf.toarray())

# 3. Création d'un DataFrame dédié à la visualisation
df_pca = pd.DataFrame(X_pca, columns=['PC1', 'PC2'])
df_pca['cluster'] = clusters

# 4. Génération du graphique de dispersion (Scatter Plot)
plt.figure(figsize=(10, 7))
sns.scatterplot(data=df_pca, x='PC1', y='PC2', hue='cluster', palette='viridis', alpha=0.6)
# Configuration de l'affichage
plt.title('Visualisation des Clusters via Réduction de Dimension (PCA)')
plt.grid(True)
plt.show()
```

FIGURE 2.12 – Implémentation de la PCA pour la visualisation spatiale

2.4.4.2 Interprétation du Scatter Plot

Le graphique de dispersion résultant (Figure 2.13) valide visuellement la cohérence de notre segmentation :

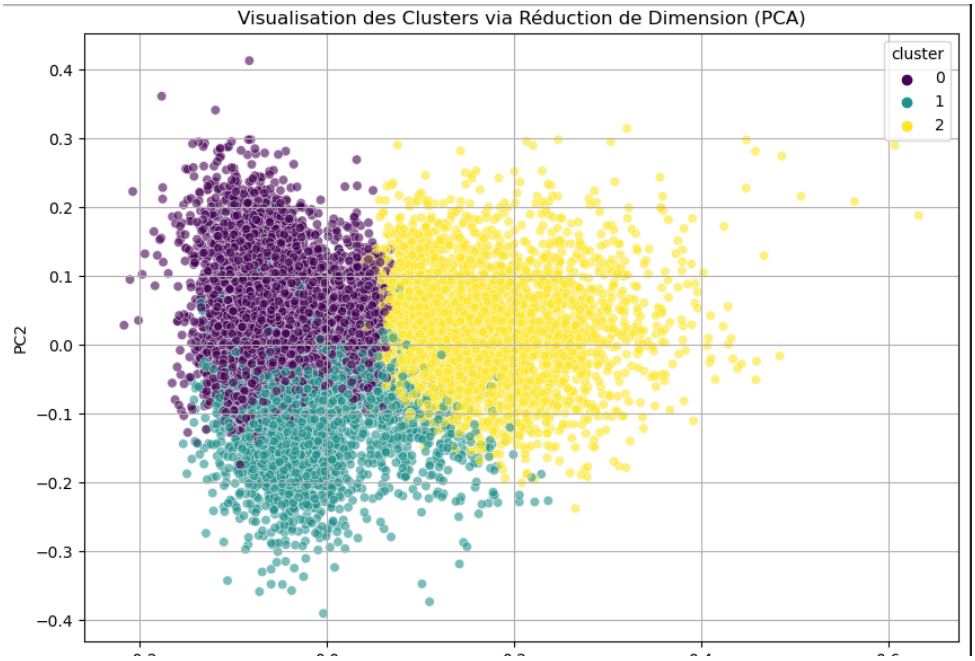

FIGURE 2.13 – Cartographie sémantique des avis clients via PCA

— **Séparation nette :** On observe trois régions bien distinctes correspondant à nos trois clusters. Cela prouve que l'algorithme K-Means a réussi à identifier des structures thématiques uniques sans chevauchement excessif.
— **Densité :** Le **Cluster 0 (Violet)** et le **Cluster 2 (Jaune)** montrent une forte densité, indiquant des thématiques très homogènes (Satisfaction et Style). Le **Cluster 1 (Vert)** est légèrement plus dispersé, reflétant la diversité des commentaires liés à la taille et aux commandes.

3. Conclusion Générale du Projet

Ce projet s'inscrit pleinement dans le domaine de la **Science des Données (Data Science) appliquée à l'analyse textuelle (*Text Mining*)**. À travers ce travail, nous avons démontré comment transformer une masse de données brutes et non structurées en connaissances stratégiques actionnables pour le secteur de l'e-commerce.

Le cycle de vie de ce projet a reposé sur une méthodologie rigoureuse, articulée autour de trois axes fondamentaux :

— **Ingénierie des données et NLP :** Une phase cruciale de prétraitement (*Cleaning, Tokenization, Lemmatization*) couplée à une vectorisation avancée par **TF-IDF**. Cette étape a permis de convertir le langage naturel en une structure matricielle exploitable par les algorithmes mathématiques.

— **Apprentissage Supervisé (Analyse Prédictive) :** En implémentant le modèle **Multinomial Naive Bayes**, nous avons conçu un classifieur capable d'identifier la satisfaction client avec une exactitude de **86%**. L'analyse critique via la matrice de confusion et le rapport de classification nous a permis de diagnostiquer précisément les performances du modèle face au déséquilibre des classes.

— **Apprentissage Non Supervisé (Analyse Descriptive) :** Grâce à l'algorithme **K-Means** et à la méthode du coude (*Elbow Method*), nous avons segmenté les avis en trois thématiques majeures (Satisfaction, Taille/Coupe, et Attributs Produits). La visualisation spatiale par **PCA** (Analyse en Composantes Principales) a validé la cohérence de cette segmentation, offrant ainsi une cartographie sémantique à 360° de l'expérience client.

En conclusion, la synergie entre ces différentes techniques de *Machine Learning* prouve que l'intelligence artificielle est un outil puissant pour l'automatisation de l'analyse des sentiments. Ce projet constitue une base solide pour des évolutions futures, telles que l'intégration de modèles de *Deep Learning* ou l'analyse en temps réel des flux de commentaires, consolidant ainsi la position de la Data Science comme pilier de la décision managériale moderne.